



视觉大模型与具身智能 专题研究

李岱勋

华山菁英副教授

西安电子科技大学

—— 2026年6月16日 ——

I 教育经历



李岱勋

华山菁英副教授

2026年博士青托

ACM MM分会主席

教育经历

- **2018-2022** **西安电子科技大学**
通信工程学院 **学士学位**
(专业: 通信工程)
- **2022-2026** **西安电子科技大学**
通信工程学院 **学术博士 (硕博连读)**
(导师: 李云松教授)
- **2023-2024** **悉尼大学 (QS排名: 19)**
计算机学院 **访问学者**
(导师: Prof. Chang Xu)

聚焦多模态大模型与具身智能研究

I 代表性论著

发表成果

- 发表中科院一区**IEEE Trans.**系列期刊、**CCF A 类**国际会议论文**20篇**
- **其中以第一作者/通讯身份发表CCF-A类论文5篇，发表SCI一区论文4篇**
- **1篇**论文获得ESI前1%高被引论文，**2篇**论文获得CCF-A类论文Oral
- **Google Scholar总被引362次，h-index指数8**

期刊/会议	论文	分区/级别	作者信息
CVPR	GeoCoT: Towards Reliable Remote Sensing Reasoning with Manifold Perspective	CCF-A类会议	第一作者
IEEE TGRS	FedFusion: Manifold-driven federated learning for multi-satellite and multi-modality fusion	SCI一区TOP IF=8.6 (ESI前1%高被引)	第一作者
ICCV	Towards Long-Horizon Vision-Language-Action System: Reasoning, Acting and Memory	CCF-A类会议	第一作者
ACM SIGKDD	FusionSAM: Visual multi-modal learning with segment anything	CCF-A类会议	第一作者
AAAI	MDFL: Multi-domain diffusion-driven feature learning	CCF-A类会议	第一作者
ACM SIGKDD	Uni-Sight: An E2E Vision-Language-Action System Unifying Multi-View Alignment and Multi-Modal Fusion	CCF-A类会议	第一作者
IEEE TCSVT	FedDiff: Diffusion model driven federated learning for multi-modal and multi-clients	SCI一区TOP IF=11.1	第一作者
Neural Networks	MMFormer: Multi-Modality Semi-Supervised Vision Transformer in Remote Sensing Imagery Classification	2024投稿为SCI一区 2026年为SCI二区	第一作者
IEEE TCSVT	Semi-mamba: Mamba-driven semi-supervised multimodal remote sensing feature classification	SCI一区TOP IF=11.1	通讯作者

I 主要科研项目

主持**中科院青年科技人才培养工程博士生专项计划**，作为骨干参与多项国家重大项目

年份	项目名称	项目性质和来源	总经费	本人参与情况
2025	中国科协青年科技人才培养工程博士生专项计划	中国科学技术协会	4万	主持
2023	面向事件认知的空天遥感边缘智能方法	国家自然科学基金委重点项目	234万	参与
2024	深空探测核心芯片基础理论及关键技术	教育部学科先导项目	1007.94万	参与
2025	智能机器人框架	工业和信息化部-国家重大项目	3000万	参与
2026	基于国产卫星的丝绸之路生态环境遥感监测和预警技术研发与应用示范	“一带一路” 战略性科技创新合作重点示范项目	962万	参与

积极围绕**国际学术组织建设、国际学术会议服务与高水平期刊评审**贡献力量

学术兼职

- 学术组织：SPIE国际光学工程学会西电图像所分会主席；IEEE GRSS西安电子科技大学学生分会主席
- 学术会议：担任第33届ACM国际多媒体会议ACM MM（CCF-A类会议）系统集成分会主席
- 学术会议：担任CVPR、ICML、AAAI等CCF-A类会议的程序委员会委员或审稿人
- 学术期刊：担任IEEE TNNLS、TCSVT、PR等SCI 一区期刊审稿人



I 平台建设

具身智能地
月协同平台



联合实验中心

月表实验场

地面指挥中心

建设**西电-逐际动力联合实验中心**：团队与中国科学院国家空间科学中心、逐际动力科技有限公司（**中国人形机器人四小龙**）建立**具身智能联合实验室**以及**非结构化复杂地形验证平台**，构建**低重力、弱光照**等极端非结构化环境下的高保真仿真与验证系统，支撑极端工况下探测车、协作机器人等智能体的感知。



I 平台建设

具身智能地
月协同平台



联合实验中心

月表实验场

地面指挥中心

建设具身智能地月协同实验场-月表实验场：建设通算控一体化地月具身智能实验场，实现智能体间通信、计算、控制高效协同，验证群体探测器在地外星表巡视、采样等任务的执行鲁棒性。



深空具身硬件平台



多地形深空验证场景



沙丘



沙坑



轨迹

I 平台建设

具身智能地
月协同平台






联合实验中心

月表实验场

地面指挥中心

搭建物理知识嵌入的月表仿真平台及其非结构化地形具身智能数据集，包含陨石坑、盆地、环形山、碎石等关键要素，支撑月球探测场景下的自主导航无人系统前期模型验证及训练。



I 平台建设

具身智能地
月协同平台




联合实验中心


月表实验场

地面指挥中心

建设**具身智能地月协同实验场-地面指挥中心**：无人系统发送控制指令，通过仿真约束模拟深空探测通信、计算能力受限条件。搭建探测器采样设备的数字孪生实体映射。



数字孪生映射



激光雷达空间信息

我对多模态大模型、具身智能、Agentic Learning充满兴趣，希望和你共同研究

课题方向

- 多模态大模型的预训练、微调、后训练，以及应用化研究
- 具身智能的视觉-语言-动作模型、视觉-语言-导航模型（双臂机器人、人形机器人、履带式机器人、机械臂）
- 多智能体、包含多智能体完成自动编程、复杂任务解译、及其Hermes、Openclaw的垂类任务研究
- 大模型、具身智能的轻量化研究

Dailies
消息 设置



具身智能任务链

机器人完成任务，需要形成从感知到执行的闭环



前端：获取与解释环境

01 感知

通过相机、深度与触觉等传感器获取环境状态。

图像 / 深度 / 接触信息

02 理解

识别物体类别、属性关系与当前任务语义。

目标 / 属性 / 场景关系

03 定位

确定目标位置、姿态以及可操作区域。

框 / mask / 位姿候选

后端：生成并修正动作

04 规划

把任务目标拆解成可执行步骤与动作顺序。

子任务 / 路径 / 策略

05 执行

控制机械臂或移动平台完成抓取、放置等操作。

动作 / 轨迹 / 控制命令

06 反馈

根据视觉与状态变化修正下一步动作，并回到新的感知。

误差 / 状态更新 / 闭环修正

讲述提纲

一

视觉基础模型概论

二

开放词汇定位感知

三

具身视觉应用前沿

I 视觉基础模型概论


1.1 早期视觉：机器首先看到的是像素

早期计算机视觉并不追求“理解世界”，而是先把现实转成可计算的图像信号。

从现实到像素矩阵

摄像机把连续世界采样为离散像素。机器最初能够处理的，只是灰度值、颜色值和局部变化，而不是“杯子”“道路”或“人”。

- ✓ 图像是数据，不是语义
- ✓ 视觉算法首先处理亮度、颜色和梯度
- ✓ 历史起点是“可计算”，不是“可理解”



I 视觉基础模型概论

图像处理阶段：从灰度变化中寻找结构

在学习模型出现之前，视觉主要依靠确定性的图像处理算子，从像素中寻找稳定结构。

滤波与增强

通过平滑、去噪和增强操作，降低图像噪声并突出结构信息。

边缘检测

寻找灰度突变的位置，用线条近似表示轮廓和边界。

阈值与区域

用规则把像素划分为前景与背景，得到初步目标区域。

I 视觉基础模型概论

边缘检测：物体轮廓的早期入口

边缘是视觉中最早被系统研究的结构之一，它把连续图像压缩成可分析的轮廓线索。

从灰度突变到轮廓

边缘检测假设：物体边界往往对应图像强度的剧烈变化。Canny 等方法让边缘提取成为早期视觉系统中的标准步骤。

- ✓ 边缘描述物体轮廓和场景结构
- ✓ 轮廓可服务识别、跟踪与三维几何
- ✓ 但边缘本身不等于语义理解



I 视觉基础模型概论

角点与局部结构：稳定的视觉锚点

角点、斑点和局部纹理让不同图像之间建立对应关系，成为匹配、拼接和跟踪的基础。

局部稳定性



角点通常在视角轻微变化后仍能被找到，因此适合做图像匹配和视觉跟踪。



语义缺失

局部特征能说明“这里相似”，但不能说明“这里是什么物体”。

I 视觉基础模型概论


I 人工特征时代：人定义什么是“有用视觉信息”

人工特征的核心思想，是把人类对图像结构的经验写进算法，让机器按规则提取。

1999–2011

SIFT / HOG / ORB

SIFT 强调尺度不变关键点，HOG 统计梯度方向，ORB 追求更高效率。它们都代表了“人设计视觉经验，机器负责执行”的时代。



机器执行提取

算法负责把规则应用到图像上。

特征用于匹配

相似特征对应相似图像区域。

识别依赖特征

分类器效果受特征质量限制。

I 视觉基础模型概论

人工特征的上限：能匹配，但难理解

人工特征让视觉具备工程可用性，但它处理的是局部结构，不是开放世界中的复杂语义。

01

光照变化

局部统计容易受环境影响

02

姿态变化

同一物体外观差异巨大

03

遮挡干扰

关键区域可能不可见

04

语义不足

特征不能表达“是什么”

I 视觉基础模型概论


1.2 统计学习：视觉开始具备识别能力

当人工特征被提取出来后，统计学习开始负责判断类别、学习边界和输出结果。

从“提取结构”到“判断类别”

这一阶段的系统通常分为两部分：前端由人工特征描述图像，后端由分类器学习如何区分不同类别。

- ✓ 特征仍然依赖人工设计
- ✓ 模型学习的是决策边界
- ✓ 识别效果高度依赖特征质量




样本被表示为特征向量，距离用于度量样本在特征空间中的接近程度。

传统识别流程：特征提取 + 分类器

传统视觉像一条手工搭建的流水线，每个环节都需要人为设计和调参。

阶段	主要作用	典型方法
输入图像	获得像素、颜色和局部结构	灰度化 / 归一化 / 滤波
特征提取	把图像变成可比较的向量	SIFT / HOG / LBP
分类判断	根据特征向量输出类别	SVM / Boosting / Random Forest
后处理	修正边界、排序候选、过滤噪声	NMS / 阈值筛选



I 视觉基础模型概论

数据集与评测：视觉研究开始标准化

数据集不仅提供训练样本，也定义任务边界、类别空间和比较方式。

视觉研究开始从“哪个方法看起来有效”，转向
“在统一基准上谁更有效”。

- ✓ 统一数据集让模型性能可比较
- ✓ 统一指标推动方法持续迭代
- ✓ 标注类别也限制了模型能识别什么

1998



MNIST

2009




CIFAR-10

2009



ImageNet



I 视觉基础模型概论

最新具身智能开源数据集：从单体到跨本体

具身智能的数据集不只提供样本，还定义机器人任务、场景分布、本体差异和评测方式。

机器人数据正在从“单实验室、单任务”转向“跨场景、跨平台、跨本体”的开放数据生态。

- ✓ **多样化场景** 从桌面实验室走向家庭、办公、厨房和真实操作环境
- ✓ **跨本体数据** 从单机械臂扩展到多机械臂、双臂、人形和移动平台
- ✓ **语言条件任务** 数据开始包含自然语言指令、目标图像和多任务示范



BridgeData V2

约 60K 轨迹；低成本机械臂；
支持语言或目标图像条件

2020



RLBench

2023



BridgeData V2

2023/24



Open X

Open X-Embodiment

1M+ 真实机器人轨迹；22 种
机器人本体；统一开源格式

DROID

76K 示范 / 350h；564 个场景
；86 个任务；分布式采集

2024



DROID

AgiBot World

开源大规模操作平台；数据、模型
、基准和生态一体化

2025



AgiBot World

2026+



更多开放数据

I 视觉基础模型概论

传统目标检测：从整图识别到局部搜索

分类只能回答图中有什么，检测进一步要求在图像中找到物体位置。

检测的早期直觉

滑动窗口

在图像上不断移动窗口，对每个候选区域进行判断。

多尺度搜索

同一目标可能大小不同，因此需要在多个尺度上重复检测。

候选区域

先生成可能目标区域，再进行分类和筛选。

历史意义

检测任务让视觉系统开始输出空间位置，但计算复杂、流程繁琐。

I 视觉基础模型概论

传统视觉的瓶颈：流程复杂，泛化有限

传统视觉已经能解决特定问题，但系统能力难以自然迁移到开放环境。

工程可控



每个模块都有明确功能，适合边界清晰、目标稳定的场景。



开放困难

光照、姿态、背景、类别变化都会破坏人工设计好的规则。

I 视觉基础模型概论


1.3 深度学习：特征开始由模型自己学习

深度学习真正改变的不是分类器，而是视觉特征的来源。

从特征工程到表征学习

CNN 把特征提取和分类判断放到同一个可训练网络中。特征不再写在规则里，而是存储在模型参数中。

- ✓ 人工特征：规则写在算法里
- ✓ CNN：特征写在参数里
- ✓ 训练数据决定表示能力



I 视觉基础模型概论

CNN 表征的层级性：从边缘到语义

CNN 的强大之处在于，它把图像理解拆成了逐层抽象的过程。

I 低层特征


边缘、颜色、纹理等局部视觉线索。

II 中层结构

局部形状、部件和重复模式。

III 高层语义

物体类别、场景概念和任务相关表征。



I 视觉基础模型概论


视觉骨干网络：模型开始被复用

随着 CNN 成熟，视觉模型不再只服务单个分类任务，而开始作为下游任务的通用特征提取器。

Backbone + Head

Backbone 负责提取通用视觉特征；不同任务头负责分类、检测、分割等具体输出。这是视觉基础模型思想的早期雏形。

- ✓ 同一骨干可服务多个任务
- ✓ 任务头决定输出形式
- ✓ 特征复用降低了重复训练成本



I 视觉基础模型概论


ResNet: 深层视觉网络真正可扩展

ResNet 解决了深层网络训练困难的问题，使视觉骨干可以稳定加深。

2015

Residual Learning

残差连接让网络学习增量映射，而不是直接学习完整变换。它缓解了深层网络退化问题，成为视觉任务中最重要的骨干之一。



CNN 的工程化成熟：视觉任务体系形成

到 ResNet 之后，CNN 已经从单个模型发展为完整的视觉工程体系。

01

骨干网络

稳定提取视觉特征

02

任务头

适配不同输出形式

03

数据基准

推动模型迭代

04

迁移复用

支持下游任务扩展

I 视觉基础模型概论

1.4 视觉任务扩展：从分类到结构化输出

视觉模型不再只判断图像类别，而是开始输出空间结构。

三类基础输出

分类回答“是什么”，检测回答“在哪里”，分割回答“边界在哪里”。
它们构成了后续视觉大模型仍然需要服务的基本输出形式。

✓ 分类：图像级语义

✓ 检测：区域级定位

✓ 分割：像素级边界

**Semantic
Segmentation**



GRASS, CAT,

**Classification
+ Localization**



CAT

**Object
Detection**



DOG, DOG, CAT

**Instance
Segmentation**



DOG, DOG, CAT

I 视觉基础模型概论

图像分类：回答“图中是什么”

分类是视觉理解的起点，但它只能给出整张图的语义判断。

优势



任务清晰、评测简单、适合训练通用视觉骨干。



不足

无法给出目标位置，也无法区分同一图像中的多个对象。

I 视觉基础模型概论



目标检测：回答“物体在哪里”

目标检测把视觉输出从整图类别推进到图像区域，是机器人目标识别的重要基础。

2014–2020

R-CNN / YOLO / DETR

检测方法从候选区域、实时单阶段检测，逐步走向端到端集合预测。
历史主线不是结构细节，而是输出从类别变成“类别 + 位置”。



I 视觉基础模型概论

图像分割：回答“边界在哪里”

分割把视觉输出从粗粒度目标框推进到像素级区域，为操作和三维落地提供基础。

2015-至今

FCN / Mask R-CNN / SAM

分割任务要求模型给出每个像素的类别或实例归属。对于机器人而言，mask 比检测框更接近可抓取、可投影、可筛选的目标区域。



I 视觉基础模型概论

任务模型的局限：强能力但弱通用

分类、检测、分割都很成熟，但它们大多依赖固定类别、固定任务和固定输出头。

CNN 时代的视觉模型很强，但多数仍是任务专用模型。

- ✓ 类别空间通常封闭
- ✓ 换任务需要重新设计或微调
- ✓ 难以直接理解自然语言目标

固定任务头

分类、检测、分割通常需要不同 head，任务之间难以自然统一。

封闭类别

模型主要识别训练数据中定义好的类别，开放世界适应弱。

重训练依赖

换任务、换类别、换场景时，往往需要重新标注和微调。

语义交互不足

用户自然语言描述难以直接进入传统视觉模型。

I 视觉基础模型概论



1.5 视觉基础模型：从任务模型到通用底座

视觉模型的发展方向，开始从“为某个任务训练”转向“先训练通用模型，再迁移到多任务”。

预训练成为新范式

基础模型强调大规模数据、统一预训练和多任务迁移。视觉模型不再只是一个分类器，而是可以被复用到检测、分割、检索、描述和交互中。

- ✓ 先学习通用视觉表征
- ✓ 再适配具体任务输出
- ✓ 模型能力开始跨任务迁移



自监督学习：从无标签图像中学习结构

自监督学习降低了人工标注依赖，让视觉模型可以利用更大规模的数据。

≈ 对比学习

让相似图像特征接近，不同图像特征远离。

▨ 遮挡重建

遮住图像一部分，让模型从局部推断整体。

◎ 自蒸馏

通过教师—学生机制学习稳定视觉表示。

视觉学习开始摆脱固定标签，向更大规模、更通用的数据学习迈进。

I 视觉基础模型概论


Transformer 的启发：统一的 token 建模

Transformer 提供了一种可以跨模态复用的建模语言：token 与 attention。

2017

Attention Is All You Need

语言模型把文本表示为 token 序列，并通过注意力机制建模全局关系。这个思想随后影响视觉、语音、视频等模态。



I 视觉基础模型概论

ViT: 图像也可以被切成 token

ViT 的历史转折在于：图像不再必须由卷积处理，也可以被转换为 visual token 序列。

2020

Vision Transformer

ViT 将图像切成 patch，每个 patch 映射为 token，再使用 Transformer 建模全局关系。它让视觉进入了与语言模型相似的架构体系。

Patch

图像被切成固定大小的小块。

Visual Token

每个 patch 被映射为一个视觉 token。

Self-Attention

Transformer 建模所有 token 之间的全局关系。

讲述提纲

- 一 视觉基础模型概论
- 二 开放词汇定位感知**
- 三 具身视觉应用前沿


II 开放词汇定位感知

2.1 从封闭类别到开放词汇

传统视觉模型通常依赖固定类别表，而真实机器人任务中的目标往往来自自然语言描述。

从标签到描述

封闭类别模型回答“这是什么类别”；开放词汇视觉进一步回答“用户描述的目标在哪里”。它把类别识别改写成语言条件下的视觉查询。



- ✓ 类别固定：训练集定义模型能识别的对象范围。
- ✓ 语言开放：用户指令会包含颜色、位置、用途和关系。
- ✓ 任务相关：目标不再只是物体类别，而是当前任务对象。

II 开放词汇定位感知

封闭类别视觉的局限

标准数据集中的类别表很清楚，但开放环境中的任务对象往往没有被提前定义。

类别固定

模型只能在训练时给定的类别集合内做判断，无法自然识别新概念。

语义贫乏

类别标签很短，难以表达颜色、材质、功能、位置和关系。

场景迁移弱

换环境、换物体或换说法后，原有分类边界容易失效。

开放环境中的机器人任务，更像“理解描述”，而不是“选择标签”。

II 开放词汇定位感知

开放词汇视觉要解决什么问题

开放词汇视觉不是把类别表变长，而是让自然语言成为视觉查询条件。

用语言查询图像，而不是用类别表限制图像。

类别

杯子、书、瓶子等基本对象名称。

属性

红色、透明、金属、可打开等视觉属性。

关系

左侧、靠近盒子、桌面上方等空间关系。

开放词汇视觉的核心，是把自然语言转成视觉系统可以执行的查询。

II 开放词汇定位感知

语言监督：开放词汇视觉的真正入口

开放词汇视觉的关键转折，不是类别数量变多，而是监督信号从“标签”变成了“自然语言”。

类别名称不再只是输出结果，
而可以成为输入条件。

CLIP: Connecting text and images

图像—文本对


图像与自然语言描述共同出现，提供开放语义监督。

Prompt 查询

类别、属性和关系可以通过文本直接进入视觉系统。

区域提取

语言目标最终需要变成框、mask 和可操作区域。



II 开放词汇定位感知

2.2 CLIP: 让图像和语言进入同一个空间

CLIP 的历史意义，是把视觉识别从固定标签分类改写为图像—文本语义匹配。

图文双塔

图像编码器和文本编码器分别提取特征，并在共同语义空间中进行匹配。模型不再只学习“类别标签”，而是学习“这张图可以怎样被语言描述”。

- ✓ 图像编码器：把图片映射为视觉向量。
- ✓ 文本编码器：把 prompt 映射为语言向量。
- ✓ 共同空间：相似图文对在空间中靠近。

Learning Transferable Visual Models From Natural Language Supervision

Abstract

State-of-the-art computer vision systems are trained to predict a fixed set of predetermined object categories. This restricted form of supervision limits their generality and usability since additional labeled data is needed to specify any other visual concept. Learning directly from raw text about images is a promising alternative which leverages a much broader source of supervision. We demonstrate that the simple pre-training task of predicting which caption goes with which image is an efficient and scalable way to learn SOTA image representations from scratch on a dataset of 400 million (image, text) pairs collected from the internet. After pre-training, natural language is used to reference learned visual concepts (or

is used to reference learned visual concepts (or describe new ones) enabling zero-shot transfer of the model to downstream tasks. We study the performance of this approach by benchmarking on over 30 different existing computer vision datasets, spanning tasks such as OCR, action recognition in videos, geo-localization, and many types of fine-grained object classification. The model transfers non-trivially to most tasks and is often competitive with a fully supervised baseline without the need for any dataset specific training. For instance, we match the accuracy of the original ResNet-50 on ImageNet zero-shot without needing to use any of the 1.28 million training examples it was trained on. We release our code and pre-trained model weights at <https://github.com/OpenAI/CLIP>.

II 开放词汇定位感知

CLIP 之前：视觉分类依赖固定标签

传统分类模型通常训练一个固定分类头，模型只能在给定标签集合中选择答案。


传统分类	CLIP
固定类别表	自然语言描述
训练分类头	计算图文相似度
类别封闭	概念开放
标签监督	语言监督

CLIP 打破的是“类别表”对视觉识别的限制。

II 开放词汇定位感知

CLIP 的训练数据：图像和文字一起学习

CLIP 用大规模图文对进行训练，使模型从自然语言中学习视觉概念，而不是只学习人工类别标签。



监督信号从人工类别
变成自然语言描述

类别

dog / cup / chair

属性

red / wooden / transparent

场景

on the table / in the room

II 开放词汇定位感知

图文对比学习：匹配的靠近，不匹配的远离

CLIP 的训练直觉很简单：正确图文对相似度升高，错误图文对相似度降低。

(1) Contrastive pre-training

正确图文对


图像和对应文字在语义空间中靠近。

错误图文对

不匹配的图像和文字被推远。

共同空间

模型最终学习“图像如何被语言描述”。



CLIP 学到的不是单个类别，而是图像和语言之间的语义对应关系。

图文相似度计算：


$$s_{ij} = \cos(v_i, t_j) = \frac{v_i^\top t_j}{\|v_i\| \|t_j\|}$$

II 开放词汇定位感知

Zero-shot: 不用重新训练也能识别新类别

CLIP 把类别名称改写成 prompt, 再与图像特征做相似度匹配。

分类结果 = 与图像最匹配的文本描述。



II 开放词汇定位感知

Prompt: 语言表达会影响视觉识别

同一个类别，简单名称、模板句和完整描述会给模型不同的语义条件。

开放词汇视觉不是只输入类别名，而是要学会用语言组织视觉查询。

dog

只有类别名，语义最短。

a photo of a dog

更接近训练数据中的图文表达。

a small brown dog on the grass

包含属性与场景信息，查询更具体。

II 开放词汇定位感知

CLIP 的能力边界：强语义，弱定位

CLIP 擅长判断图像与文本是否相关，但原始形式并不直接输出目标框或 mask。

CLIP 能做什么

- ✓ 图文检索
- ✓ Zero-shot 分类
- ✓ 语义匹配

CLIP 不能直接做什么

- ✓ 精确目标框
- ✓ 像素级 mask
- ✓ 机器人可操作边界

CLIP 让视觉听懂语言，但还没有告诉机器人目标精确在哪里。

II 开放词汇定位感知

CLIP 对具身智能的意义

用户不会按照数据集类别表下命令，而会使用自然语言描述任务目标。

“拿起桌面左侧的红色杯子”

目标

杯子

属性

红色

位置

桌面左侧

任务

拿起

CLIP 的价值不是直接控制机器人，而是把自然语言任务引入视觉感知链路。

II 开放词汇定位感知

从 CLIP 到 Grounding：为什么需要区域级开放视觉

CLIP 能判断图文是否相关，但机器人任务需要知道文本目标在图像中的具体位置。

1 CLIP：全图语义匹配

判断“这张图”和“这段文本”是否在语义上接近，适合分类、检索和概念判断。

2 Grounding：区域级定位

把文本目标落到二维图像区域中，输出与语言描述相关的候选框。

3 机器人：可执行区域

后续分割、投影、抓取都依赖明确的目标区域，而不是整图语义分数。

全图相关 → 区域定位 → 像素分割

开放词汇检测的价值，是把“语言中的目标”转化为“图像中的候选区域”。

II 开放词汇定位感知

开放词汇检测：用文本指定目标框

开放检测把“用户说的目标”转换成图像中的二维候选区域。

输入


图像 + 文本 prompt。

输出

与文本相关的目标框。

价值

语言目标开始拥有图像坐标。



开放词汇检测让“语言中的目标”第一次具有了图像坐标。

II 开放词汇定位感知

Grounding DINO: 文本到框的工程桥梁

Grounding DINO 的作用，是把自然语言目标定位到图像区域，为后续分割提供提示。

文本条件检测

输入不再是固定类别，而是自然语言 prompt。

跨模态特征

图像区域与文本 token 建立对应关系。

SAM 前置模块

先给框，再由 SAM 生成精细 mask。

Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection

Shilong Liu^{1,2*}, Zhaoyang Zeng², Tianhe Ren², Feng Li^{2, 3}, Hao Zhang^{2, 3},
Jie Yang^{2, 4}, Qing Jiang^{2, 6}, Chunyuan Li⁵, Jianwei Yang⁵,
Hang Su¹, Jun Zhu^{1**}, Lei Zhang^{2**}.

¹ Dept. of Comp. Sci. and Tech., BNRist Center, State Key Lab for Intell. Tech. & Sys.,
Institute for AI, Tsinghua-Bosch Joint Center for ML, Tsinghua University

² International Digital Economy Academy (IDEA)

³ The Hong Kong University of Science and Technology

⁴ The Chinese University of Hong Kong (Shenzhen) ⁵ Microsoft Research, Redmond

⁶ South China University of Technology

liusl20@mails.tsinghua.edu.cn, leizhang@idea.edu.cn




Fig. 1: (a) Closed-set object detection requires models to detect objects of pre-defined categories. (b) We evaluate models on novel objects and standard Referring expression comprehension (REC) benchmarks for model generalizations on novel objects with attributes. (c) We present an image editing application by combining Grounding DINO and Stable Diffusion [41]. Best viewed in colors.

II 开放词汇定位感知

Grounding DINO 的整体结构

Grounding DINO 不是普通检测器，而是把图像特征和文本特征一起送入检测流程。

1 Image Backbone

提取图像中的多尺度视觉特征，为候选区域提供外观与位置信息。

2 Text Encoder

把 prompt 中的类别、属性和关系编码成文本 token 表示。

3 Feature Enhancer


让视觉 token 与文本 token 进行跨模态特征交互。

4 Decoder

根据语言条件输出相关目标框和文本匹配分数。

图像特征 + 文本特征 共同参与检测过程

- ✓ 核心变化：检测目标不再来自固定类别表，而是来自输入 prompt。
- ✓ 输出结果：与文本语义最相关的一组二维目标框。



II 开放词汇定位感知

文本分支：Prompt 如何进入检测器

Prompt 不是简单类别名，它可以包含类别、属性、关系和短语，使检测目标更接近自然语言任务。

Prompt 可以描述什么？

- 类别：cup / bottle / tool
- 属性：red / transparent / metal
- 关系：on the table / near the box
- 短语：red cup on the left side

从“类别检测”到“语言条件检测”

固定类别表 → 可变 prompt

检测器需要理解的不再只是“cup”，还包括“红色的、在桌面左侧的、可被拿起的杯子”。

文本 token 让检测目标从固定标签变成可变化的语言条件。


II 开放词汇定位感知

跨模态特征增强：Feature Enhancer Layer

Grounding DINO 通过双向注意力，让文本 token 和图像区域在检测前完成特征交互。

不是先检测再匹配文本，而是在检测前就让区域特征带上语言条件。

- **Text-to-Image** 文本作为查询，强化与描述相关的图像区域。
- **Image-to-Text** 图像区域反向更新文本特征，让短语更贴近当前场景。
- **Self-Attention / FFN** 分别在文本和图像内部整合上下文，再输出更新后的特征。



这一层的作用：让“红色杯子”这类文本约束直接影响候选区域选择。

II 开放词汇定位感知

Language-Guided Query Selection

语言引导 query 选择，使检测器优先关注与文本最相关的图像区域。

普通检测	Grounding DINO
固定 query 寻找所有潜在物体	根据输入文本筛选相关候选区域
类别空间主要来自训练集标签	目标空间由 prompt 动态指定
输出 “图中有什么”	输出 “文本目标在哪里”

检测直觉

不是盲目寻找所有物体，
而是先让文本告诉模型：
“哪些区域值得被查询”。

- ✓ 图像 token 与文本 token 计算相关性。
- ✓ 相关性高的区域更容易进入后续 decoder。

检测过程从 “找所有物体” 变成 “找文本指定的物体”。


II 开放词汇定位感知

Grounded-SAM: 开放检测 + 提示分割

在工程系统中，Grounding DINO 与 SAM 常组合使用，完成从文本目标到像素 mask 的转换。

Grounded-SAM 把“自然语言目标”转化为“像素级可用区域”。

阶段	输出
文本目标	red cup on the table
目标框	文本相关区域
目标 mask	像素级目标边界



II 开放词汇定位感知


2.4 SAM 三部曲：分割能力的三次升级

SAM 系列的演进，是从“给提示分割一个目标”走向“给概念发现全部目标”。

三次升级

SAM 解决图像提示分割；SAM 2 扩展到视频；SAM 3 走向概念级发现、分割和跟踪。三者共同推动分割从交互工具走向开放视觉能力。

- ✓ SAM：提示式图像分割。
- ✓ SAM 2：图像 + 视频持续分割。
- ✓ SAM 3：概念级实例发现与跟踪。



II 开放词汇定位感知

SAM: 分割从固定类别变成提示驱动

SAM 的关键变化，是把“分割什么”交给提示来决定，而不是预先限定在固定类别表中。

输入提示


点、框或已有 mask。

输出结果

一个或多个候选 mask。

核心变化

类别不再固定，目标由提示指定。



SAM 把分割任务从固定类别预测，改写为提示条件下的区域生成。

II 开放词汇定位感知

SAM 的三个组件

SAM 的结构可以用三个模块理解：看图、理解提示、输出 mask。

Image Encoder


提取整张图像的高维视觉特征。

Prompt Encoder

把点、框、mask 转成模型可理解的条件。

Mask Decoder

融合图像特征与提示信息，输出候选 mask。



II 开放词汇定位感知

提示方式：点、框、mask

不同提示适合不同使用场景，本质上都是在告诉模型“我想分割哪个目标”。

提示机制让分割目标从固定类别变成外部条件。

提示类型	使用直觉
点提示	快速指定前景或背景区域。
框提示	给出目标的大致范围，适合与检测器组合。
mask 提示	在已有区域基础上进一步细化。

点提示



框提示




mask提示



II 开放词汇定位感知

SAM 的多候选 mask

同一个提示可能对应不同粒度的区域，因此 SAM 通常会保留多个候选 mask。



局部部件

只分割物体的一部分。

完整物体

分割主要目标本身。

上下文区域

包含与目标相关的周围区域。

多候选输出保留了分割的不确定性，也给后续任务留下选择空间。

II 开放词汇定位感知

SAM 对机器人有什么用

SAM 不直接控制机器人，但它提供了从二维语义到三维几何的关键边界表示。

目标框 → mask 检测结果被细化为精确目标区域。

mask + 深度图 只保留目标区域对应的三维点。

目标点云 → 抓取 为位姿估计和抓取规划提供输入。

SAM 是二维语义感知进入三维执行链路的关键接口。



II 开放词汇定位感知

SAM 2: 从单张图像走向视频

机器人执行过程中目标会运动、遮挡和短暂消失，因此单帧分割不足以支撑闭环。

图像分割

单帧中指定目标区域。

视频分割

跨帧维持目标 mask。

身份保持

持续追踪同一目标实例。

SAM 2 让分割结果从单帧目标变成连续时序目标。



II 开放词汇定位感知

视频分割的新问题：目标不是静止的

SAM 2 需要面对的，不只是多一帧图像，而是目标在时间中的持续变化。

1 目标会移动

同一物体在不同帧中位置不断变化。

2 视角会变化

相机或机器人运动导致外观变化。

3 物体会被遮挡

机械臂、手或其他物体可能挡住目标。

4 相似物体干扰

多个相似对象容易造成身份混淆。

5 结果要连续

mask 不应每一帧重新随机选择目标。

单帧分割只解决“这一帧在哪里”，视频分割还要解决“下一帧还是不是它”。

II 开放词汇定位感知

SAM 2 的任务变化：从单帧分割到视频目标跟踪

SAM 2 的输出不再只是某一帧的 mask，而是视频中连续保持身份的目标 mask 序列。

SAM 2 让分割从静态区域变成可追踪的时序对象。

1 Image mask

单张图像中的目标区域，回答“这一帧目标在哪里”。

2 Video masks

跨多个视频帧的 mask 序列，回答“目标如何随时间变化”。

3 Object identity

在连续帧中保持同一实例身份，避免目标漂移和混淆。

mask → masks → identity-aware tracking

✓ 对于视频任务，分割结果必须同时具备空间边界和时间连续性。

II 开放词汇定位感知

SAM 2 的核心：记忆机制

SAM 2 通过保存历史帧中的目标信息，在当前帧中检索记忆并更新 mask。


对于机器人，记忆机制意味着目标在执行过程中可以被持续追踪，而不是每一帧都重新“猜一次”。

历史帧：保存目标信息

目标外观、位置和 mask 信息被写入 memory。

当前帧：检索记忆

当前图像通过注意力机制查找相关历史目标。



II 开放词汇定位感知

Memory Bank: 历史帧如何帮助当前帧

SAM 2 通过保存历史帧中的目标信息，在当前帧中检索记忆并更新 mask。


历史帧：保存目标信息

- 目标外观：颜色、纹理、形状
- 目标位置：前一帧空间分布
- 目标 mask：已确认的区域边界

Memory
Attention
→

当前帧：检索并更新

- 根据当前图像寻找历史目标
- 用 memory 修正当前 mask
- 把新结果继续写回记忆



II 开放词汇定位感知

交互式纠错：一次提示不够时怎么办

SAM 2 的重要价值在于：视频分割可以持续交互，错误可以在后续帧被修正。

SAM 2 不只是自动跟踪工具，也是可交互的视频分割系统。

1 初始提示

在第一帧通过点、框或 mask 指定目标。

2 中途纠错

目标遮挡、漂移或分割错误时，在后续帧补充提示。

3 后续传播

修正后的目标信息继续传播到后续视频帧。

用户 / 系统提示 → 模型更新目标记忆 → 后续帧继续追踪

✓ 这种机制适合机器人闭环执行，因为操作过程中目标状态会不断变化。

II 开放词汇定位感知

SAM 2 对具身任务的意义

真实操作不是单帧任务，机器人需要在动作过程中持续更新视觉目标。

抗短时遮挡

目标被机械臂遮挡后仍可恢复。

保持目标身份

避免多物体场景中的目标漂移。

在线视觉更新

执行中根据反馈修正目标 mask。

SAM 2 更接近真实机器人执行，因为真实操作不是单帧任务。



II 开放词汇定位感知

| SAM3 不是 SAM2 的简单视频增强

SAM2 解决 “这个目标在后续帧去哪了” ； SAM3 更进一步，解决 “哪些对象属于这个概念” 。

对比维度	SAM2	SAM3
任务核心	给定一个目标，持续跟踪它	给定一个概念，发现全部实例
主要提示	点、框、mask 等空间提示	文本短语、图像示例或二者组合
输出对象	单个目标的跨帧 mask	所有匹配实例的 mask 与身份
能力重点	目标延续与交互纠错	开放概念的检测、分割与跟踪

II 开放词汇定位感知

SAM3 的整体结构：检测与跟踪统一


SAM3 可以理解为“图像级检测器 + 基于记忆的视频跟踪器”，二者共享视觉骨干。

Image-level Detector: 在单张图像中根据概念提示发现所有相关实例。

Memory-based Tracker: 在视频中延续实例身份并更新 mask。

Shared Backbone: 图像与视频能力共用底层视觉表示。


Concept Prompt: 文本或示例提示贯穿检测、分割和跟踪过程。



II 开放词汇定位感知

| Promptable Concept Segmentation: 任务定义

PCS 的目标是：给定一个概念提示，在图像或视频中返回所有匹配实例的 mask 与身份。



PCS 面向的是“概念下的所有实例”，而不是单个交互式目标。

II 开放词汇定位感知

| SAM3 对具身视觉的意义

具身系统面对的不是静态数据集标签，而是自然语言任务、多个候选目标和持续变化的场景。

1 用户说的是概念

例如“把红色杯子拿过来”，不是给坐标或类别编号。

2 场景里有多个候选

系统需要先发现全部候选，再结合任务约束筛选目标。

3 执行中需要跟踪身份

同一目标在视频中移动、遮挡或被机械臂部分遮住。

4 结果需要进入后续模块

mask 与身份可以继续用于深度投影、抓取选择和动作反馈

。

SAM3 让具身系统从“点一下这个目标”走向“理解并发现某类任务目标”。

II 开放词汇定位感知

2.5 面向具身智能的二维感知链路

建立一条二维感知链路：自然语言目标如何变成图像中的可用区域。

语言到区域

CLIP 提供语义对齐思想，Grounding 输出目标框，SAM 将框或提示细化为 mask。三者合在一起，构成具身系统最常用的二维开放感知链路。

- ✓ 语义匹配：文本与图像概念建立对应。
- ✓ 区域定位：语言目标落到二维图像区域。
- ✓ 像素分割：获得可投影、可筛选的目标 mask。



Only Image Inputs

RAM-Grounded-SAM



Automatically Generate Tag, Box, and Mask Annotations

"armchair, blanket, lamp, carpet, couch, dog, floor, furniture, gray, green, living room, picture frame, pillow, plant, room, sit, stool, wood floor"

II 开放词汇定位感知

这条链路的能力边界

二维开放感知能给出语义、框和 mask，但机器人执行还需要深度、位姿和坐标变换。

二维感知能给什么

- ✓ 类别语义
- ✓ 目标框
- ✓ 像素级 mask

机器人还需要什么

- ✓ 深度图 / 点云
- ✓ 三维位置 / 位姿
- ✓ 可抓取区域 / 轨迹

二维视觉大模型解决了“看见目标”，但还没有解决“在空间中操作目标”。

II 开放词汇定位感知

第二章小结：从语言到二维目标区域

核心是把自然语言目标转化为图像中的可用区域，为三维落地做准备。

CLIP

让视觉听懂语言。

Grounding

让语言落到区域。

SAM

让区域变成 mask。

下一章：视觉大模型前沿应用

讲述提纲

- 一 视觉基础模型概论
- 二 开放词汇定位感知
- 三 具身视觉应用前沿**

III 具身视觉应用前沿

3.1 视觉大模型如何进入具身智能

具身智能中的视觉大模型，不只是识别图像，而是把环境转化为机器人可以理解、规划和执行的任务信息。

从“看懂图像”到“支撑执行”

视觉大模型提供开放目标感知、场景语义理解和动态视觉反馈。它并不单独替代机器人系统，而是成为连接感知、规划与动作的接口。

目标发现

在开放场景中找到用户描述的对象

场景理解

判断物体关系、状态与任务条件

操作规划

把语义目标转为可执行约束

执行反馈

在动作过程中持续更新视觉状态

III 具身视觉应用前沿

本章应用地图

VLM 场景理解

看懂场景与任务状态

VLN 语言导航

根据语言指令移动

开放目标感知

用文本定位目标区域

视频目标跟踪

执行中持续盯住目标

VLM + 3D 规划

把语言转为空间约束

VLA 通用控制

视觉语言动作统一

OpenVLA 部署

开源可微调机器人策略

动作生成策略

Octo / Diffusion Policy

主线：开放感知 → 场景理解 → 空间规划 → 动作执行

III 具身视觉应用前沿

应用一：VLM 让机器人看懂场景

VLM 的作用不是直接输出框或 mask，而是把视觉观察转化为语言层面的场景理解。

图：桌面 / 厨房 / 机器人第一视角场景
来源：LLaVA 项目页、Gemini Robotics-ER 官方示例

Q：桌面上有哪些物体？

A：桌面上有杯子、书、盒子和水瓶。

Q：哪个物体适合装水？

A：杯子更适合，因为它是容器。

Q：当前任务是否完成？

A：如果杯子已经被放到指定位置，则任务完成。

- ✓ 物体清单与属性描述
- ✓ 空间关系与任务状态
- ✓ 自然语言交互与解释

III 具身视觉应用前沿

VLM 在具身任务中的作用边界

VLM 很适合解释场景和回答问题，但它通常不是低层精确感知模块。

VLM 擅长	VLM 不擅长
场景描述	精确边界
任务问答	像素级 mask
语义推理	稳定三维位姿
人机交互	低延迟控制

关键判断

VLM 负责“理解与解释”，Grounding / SAM 负责“定位与分割”。具身系统通常需要把它们组合起来，而不是只依赖单一模型。

III 具身视觉应用前沿

VLM 与 Grounding / SAM 的分工

VLM 可以判断 “应该拿哪个物体”，但最终还需要区域定位和像素分割给出可用目标区域。

VLM

理解任务语义
判断候选目标

Grounding DINO

定位语言目标
输出目标框

SAM / SAM2 / SAM3

生成目标 mask
或持续跟踪实例


“把红色杯子放进盒子里”

- ✓ VLM 解析目标和任务意图
- ✓ Grounding 输出红色杯子的候选框
- ✓ SAM 细化为可投影、可筛选的 mask

III 具身视觉应用前沿

应用二：VLN，让机器人听懂路线指令

VLN 的任务是：给定自然语言导航指令，智能体根据视觉观察逐步走到目标位置。



Walk toward the railing and right past the stairs. Walk into the living room and turn right. Stop by the end table.

语言指令

“走出卧室，经过走廊，在厨房门口左转。”

- ✓ 读取连续语言指令
- ✓ 观察当前第一视角画面
- ✓ 选择下一步移动方向
- ✓ 根据新观察修正路线

VLN 的难点：语言、视觉和动作必须对齐

VLN 不是简单的目标识别，而是连续空间中的语言条件决策。

语言理解	视觉定位	动作决策
理解路线描述	识别地标和方位	选择移动方向
解析先后顺序	判断当前位置	修正路径偏差
处理歧义表达	记忆经过区域	避开障碍物

III 具身视觉应用前沿

VLN 对具身智能的意义

VLN 将自然语言任务扩展到移动空间，让机器人从“看图理解”走向“在环境中行动”。

语言变成路径目标

用户描述路线、地标和方向，模型需要把语言映射到可移动空间。

视觉变成位置判断

第一视角观察用于判断当前处于哪个区域、接近哪个目标。

导航变成连续决策

每一步动作都会改变后续观察，因此需要持续更新计划。



Leave the bedroom, and enter the kitchen. Walk forward, and take a left at the couch. Stop in front of the window.

应用三：开放词汇目标寻找

机器人任务中的目标通常不是固定标签，而是用户用自然语言描述的当前任务对象。



Automatically Generate Tag, Box, and Mask Annotations

指令成分	视觉含义
杯子	目标类别
红色	视觉属性
桌面左侧	空间关系
拿起	操作意图

例：拿起桌子上的茶杯

III 具身视觉应用前沿

从目标框到可操作区域

检测框适合“找到物体”，mask 更适合“操作物体”。

目标框	目标 mask
给出粗略位置	给出精确边界
可能包含背景	可以筛选目标区域
适合检测与检索	更适合抓取、投影和几何计算

具身意义

机器人操作的是物体区域，而不是矩形框；mask 可以作为后续抓取、点云筛选和轨迹规划的入口。

开放词汇感知如何服务抓取

开放词汇感知不会直接完成抓取，但它可以把用户语言转化为后续操作模块所需的目标区域。

语言目标

“拿起红色杯子”

目标 mask

定位并分割目标区域

抓取候选区域

为抓取规划提供输入

- ✓ mask 提供目标边界
- ✓ 深度或点云进一步给出空间位置
- ✓ 抓取规划器生成候选抓取姿态

III 具身视觉应用前沿

应用四：视频目标跟踪

机器人执行不是单帧任务，目标会移动、遮挡，也可能被机械臂短暂挡住。

- ✓ 跨帧保持目标 mask
- ✓ 短时遮挡后恢复目标
- ✓ 执行过程中持续更新视觉状态

关键变化

从“看见这一帧的目标”转向“持续盯住同一个目标”。



III 具身视觉应用前沿

从“看见目标”到“持续盯住目标”

SAM2 / SAM3 在具身应用中提供动态目标状态，而不是直接替代控制器。

单帧感知	视频闭环感知
只看当前帧	维护目标历史
目标容易丢失	可恢复目标身份
适合静态图像	适合执行过程
输出一次 mask	持续更新 mask / track


III 具身视觉应用前沿

应用五：从语言指令到空间约束

有些任务不是简单抓取，而是要求满足空间关系、避障、接近或接触等约束。

任务示例

“把杯子放到盘子旁边。”
“打开抽屉，但不要碰到旁边的碗。”



Affordance

哪里适合操作

Constraint

哪里不能碰 / 应靠近哪里


Value Map

空间中哪里更符合任务目标

III 具身视觉应用前沿

VoxPoser: 用 VLM 生成 3D Value Map

VoxPoser 把语言任务中的 affordance 和 constraint 转换成空间价值地图，再交给运动规划器生成轨迹。



Interactive Value Map 1

Interactive Value Map 2

LLM

理解任务与约束

VLM

关联视觉观察与对象

3D Value Map

把语言约束落到空间

Planner

根据价值地图规划轨迹

应用意义

VoxPoser 代表模块化路线：视觉语言模型不直接输出动作，而是生成机器人规划可用的空间约束。

III 具身视觉应用前沿

模块化路线的价值

具身智能并不只有端到端一种路线，模块化系统在教学、调试和工程落地中仍然非常重要。

模块化路线	端到端路线
感知、规划、控制分开	观察直接映射到动作
可解释性强，便于调试	表达能力强，但依赖大数据
能接入现有机器人系统	泛化潜力更大
适合课程教学与工程验证	适合前沿研究与大规模训练

III 具身视觉应用前沿

应用六：VLA，把视觉、语言和动作统一起来

VLA 的目标，是让模型不仅能看懂和说清楚，还能直接产生机器人动作。

图像 / 视频观察

机器人当前看到什么

自然语言指令

用户希望完成什么

机器人状态

关节、末端、历史动作

VLA 输出

动作 token
末端位姿
轨迹片段



put strawberry
into the correct
bowl



pick up the bag
about to fall
off the table



move apple to
Denver Nuggets



pick robot



place orange in
matching bowl



move redbull can
to H



move soccer ball
to basketball



move banana to
Germany



move cup to the
wine bottle



pick animal with
different colour

III 具身视觉应用前沿

RT-2：网络知识迁移到机器人控制

RT-2 的核心是把互联网规模视觉语言知识迁移到机器人动作输出中。



- ✓ 以视觉语言模型作为基础
- ✓ 将机器人动作表示为 token
- ✓ 将 VLM 语义知识迁移到操作任务
- ✓ 支持新物体、新指令的泛化

关键判断

RT-2 不是让机器人会“说话”，而是让视觉语言知识开始影响动作输出。

III 具身视觉应用前沿

Gemini Robotics: 多模态模型进入物理世界

Gemini Robotics 代表了通用多模态模型向真实机器人控制和具身推理扩展的最新方向。



多模态理解

理解图像、语言和任务上下文

具身推理

在物理世界中进行空间和逻辑判断

多步任务规划

根据自然语言规划操作步骤


动作执行

将视觉和指令转为机器人动作

III 具身视觉应用前沿

应用七：OpenVLA，开源 VLA 的代表路线

OpenVLA 的意义，是把 VLA 从封闭展示推进到可复现、可微调的研究平台。



- ✓ 7B 参数开源 VLA
- ✓ 基于真实机器人演示数据训练
- ✓ 输入图像与语言指令
- ✓ 输出机器人动作
- ✓ 支持新任务适配

OpenVLA 的输入与输出

OpenVLA 和普通 VLM 的关键差异在于：输出不再是文字回答，而是机器人动作。

普通 VLM	OpenVLA
图像 + 文本 → 文本回答	图像 + 指令 → 机器人动作
面向问答和描述	面向执行和控制
看懂图像	控制机器人
语义任务	操作任务

III 具身视觉应用前沿

| OpenVLA 对教学和研究的意义

OpenVLA 适合放进课程，是因为它提供了可复现、可微调、可实验的 VLA 路线。

Reproduce

复现模型结构与推理流程

Fine-tune

在新机器人任务上做适配


Deploy

连接真实机器人执行动作

III 具身视觉应用前沿

应用八：从 VLA 到通用机器人策略

有些模型不强调“会说话”，而是强调在多任务、多机器人数据上学习可迁移的动作策略。



多任务数据

从不同机器人平台和操作任务中学习共享动作先验。

视觉观察条件

图像、语言或目标图像作为策略生成的条件。


动作序列生成

模型输出未来动作片段，而不是单步分类结果。

III 具身视觉应用前沿

Octo: 通用机器人策略模型

Octo 是面向机器人操作的开源通用策略模型，强调跨任务、跨平台预训练与快速适配。



- ✓ Transformer-based diffusion policy
- ✓ 基于 Open X-Embodiment 大规模机器人数据
- ✓ 支持语言命令或目标图像条件
- ✓ 可快速微调到新观察和动作空间

III 具身视觉应用前沿

第三章小结：视觉大模型如何支撑具身智能

视觉大模型在具身智能中不是单独替代机器人系统，而是在感知、理解、规划和执行之间建立更开放的接口。

场景理解

VLM / Gemini Robotics-ER

目标感知

Grounding DINO / SAM

导航移动

VLN

空间规划

VoxPoser

动作执行

RT-2 / OpenVLA / Octo

核心主线：从开放感知走向具身执行



图像传输与处理研究所
Image Processing and Image Communication

感谢大家到场 谢谢大家！

李岱勋

西安电子科技大学

—— 2026年6月16日 ——